

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ОДЕСЬКА ПОЛІТЕХНІКА»
ІНСТИТУТ КОМП'ЮТЕРНИХ СИСТЕМ
КАФЕДРА ІНФОРМАЦІЙНИХ СИСТЕМ

ПРОТОКОЛ
лабораторної роботи №1
«Розгортання середовища та порівняльний аналіз мовних моделей»

Виконав(-ла):	Студент групи AI-242
	Левентій Дмитро Олександрович
Перевірів:	ас. Баранов О.М.

Одеса – 2026

Завдання 1. Ціна роздумів: міркувальна vs інструктивна модель

Виконано запити до двох моделей через ендпойнт `/api/generate`. Спочатку — просте фактичне питання, потім — задача на міркування (5 запусків для кожної моделі).

Таблиця 1 — Фактичне питання «Столиця України? Відповідай одним словом.»

Показник	qwen3:4b	llama3.2:3b
response	Київ	Київ.
eval_count	223	5
Час, с	7,64	0,41
Токенів/с	31,2	36,9

Таблиця 2 — Задача на міркування (середнє з 5 запусків)

Показник	qwen3:4b	llama3.2:3b
Правильних із 5	3 / 5	3 / 5
eval_count	1414,67	210,75
Час, с	48,88	6,46

Типова помилка інструктивної моделі: відповідь «10 грн», отримана без урахування того, що різниця у 100 грн розподіляється між двома доданками.

Відповіді на питання (крок 6)

1. Куди пішли додаткові токени в міркувальній моделі?

Відповідь: Токени пішли в поле `thinking` — модель прогнала внутрішні роздуми над очевидним фактом, перш ніж дати ту саму відповідь.

2. На яких типах задач міркувальні моделі дають перевагу над інструктивними, а на яких їх використання не виправдане?

Відповідь: Перевага — на задачах у кілька кроків (математика, логіка, планування), де проміжний результат потрібно тримати в тексті. На простих фактичних питаннях і коротких відповідях режим міркування лише витрачає час і токени.

3. Чим відрізняється процес навчання міркувальної моделі від інструктивної?

Відповідь: Міркувальну модель додатково донавчають (напр. RL) генерувати ланцюжок роздумів (`chain-of-thought`) перед фінальною відповіддю. Інструктивну вчать одразу видавати готову відповідь без проміжного тексту.

4. Чи означає більша кількість згенерованих tokenів у міркувальній моделі, що вона «розумніша» за інструктивну?

Відповідь: Ні. Кількість tokenів характеризує обсяг роботи, яку модель собі призначила, а не якість чи «розум» — вона може довго міркувати і все одно помилитися.

5. Як пояснити різницю у швидкості генерації (tokenів за секунду) між моделями `qwen3:4b` та `llama3.2:3b`?

Відповідь: Tokenів/с у моделей приблизно однакові (31,2 і 36,9) — це показник заліза й розміру моделі. Різниця в загальному часі відповіді пояснюється кількістю згенерованих tokenів (223 проти 5), а не швидкістю обладнання.

Висновок за завданням 1

Експеримент показав, що два показники — швидкість генерації та загальний час відповіді — не можна плутати. Перший характеризує обладнання й розмір моделі, другий — обсяг роботи, яку модель собі призначила. На фактичному питанні режим міркування виявився чистою перевитратою: результат однаковий, витрати відрізняються у ___ разів. На задачі про ручку й зошит ситуація протилежна — саме розписаний хід дозволяє уникнути інтуїтивно привабливої, але неправильної відповіді. Практичний висновок: тип моделі варто обирати під тип задачі.

Завдання 2. Роль system-повідомлення: керування поведінкою моделі

Варіант: «Поясни різницю між списком і кортежем у Python.» Виконано для двох моделей із двома варіантами system-повідомлення.

Таблиця 3 — Вплив system-повідомлення

Модель	System	Довжина відповіді, символів	Мова відповіді	К-сть речень	Інструкцію виконано?
llama3.2:3b	лаконічний асистент	~230	українською	4	так (коротко й по суті)
llama3.2:3b	укр., 2 речення	~330	українською	2	так
qwen3:4b	лаконічний асистент	212	українською	2	так
qwen3:4b	укр., 2 речення	~330	українською	2	так

Таблиця 4 — Витрати токенів

Модель	System	prompt_tokens	completion_tokens	total_tokens
llama3.2:3b	лаконічний асистент	55	1889	1944
llama3.2:3b	укр., 2 речення	63	99	162
qwen3:4b	лаконічний асистент	65	2445	2510
qwen3:4b	укр., 2 речення	74	644	718

Завдання 3. Локальна vs хмарна модель: єдиний інтерфейс

Варіант: «Поясни різницю між списком і кортежем у Python. Коротко.» Виконано через providers.py / compare.py.

Таблиця 5 — Порівняння локальної та хмарної моделі

Показник	Локальна	Хмарна
Назва моделі	llama3.2:3b	gemini-3.6-flash
Час відповіді, с	5.40	8.06
completion_tokens	90	297
Довжина відповіді, символів	322	895
Мова відповіді	українською	українською
Фактичних помилок у відповіді	так (нечітке/помилкове пояснення "одночасно для програмістів")	ні

Завдання 4. Вимірювання швидкості: TTFT і залежність від довжини запиту


Виконано через benchmark.py: три повтори з медіаною для кожної комбінації провайдер × промпт.

Таблиця 6 — Результати вимірювання швидкості

Розміщення	Модель	Промпт	TTFT, с	Всього, с	Симв./с
локальна	llama3.2:3b	короткий	2.04	2.418	14.5
локальна	llama3.2:3b	середній	2.074	2.868	78.6
локальна	llama3.2:3b	довгий	2.051	8.68	108.3
хмарна	gemini-3.6-flash	короткий	2.845	2.858	12.0
хмарна	gemini-3.6-flash	середній	6.437	7.318	73.9
хмарна	gemini-3.6-flash	довгий	8.455	16.275	236.6

Таблиця 7 — Холодний і теплий старт локальної моделі

Показник	Холодний старт	Теплий старт
TTFT, с	2.037	2.04
Всього, с	2.336	2.418



Завдання 5. Оцінювання якості моделей за рубрикою

Виконано через quality.py: кожне завдання прогнано двічі для кожної моделі, відповіді збережено у quality.json.

Таблиця 13 — Оцінка якості за рубрикою

Завдання	llama3.2:3b	qwen3:4b	Хмарна модель
1. Факт	2	2	2
2. Формат	2	2	2
3. Стиснення	0	2	2
4. Код	1	2	2
5. Логіка	0	2	2
6. Українська	0	2	2
Разом /12	5	12	12

Таблиця 14 — Розбіжність оцінок між двома прогонами (так / ні)

Завдання	llama3.2:3b	qwen3:4b	Хмарна модель
1. Факт	ні	ні	ні
2. Формат	ні	ні	ні
3. Стиснення	ні	ні	ні
4. Код	так	ні	ні
5. Логіка	ні	ні	ні
6. Українська	ні	ні	ні

Завдання 6. Керування випадковістю: temperature і top_p

Виконано через sampling.py.

Таблиця 16 — Вплив параметрів на різноманітність відповідей

Параметр	Значення	Унікальних із 5 (творче)	Правильних із 5 (фактичне)
temperature	0.0	1	0/5
temperature	0.7	5	—
temperature	1.5	5	0/5
top_p	0.1	1	—
top_p	0.5	5	—
top_p	1.0	5	—

Таблиця 17 — Перевірка відтворюваності

Показник	Значення
Кількість запусків	10
temperature	0.0
Унікальних відповідей	1
Усі відповіді однакові (так/ні)	так

Підсумкове порівняння моделей

Критерій	Локальна мала (3B)	Локальна більша (4B/8B)	Хмарна
Швидкість генерації	~14–108 симв./с (в середньому ~67)	~29 токенів/с* (окремо не бенчмаркалась символами)	~12–237 симв./с (в середньому ~108)
TTFT	~2.0–2.1 с (майже не залежить від довжини)	дані відсутні (не заміряно)	2.8–8.5 с (зростає з довжиною)
Якість, балів /12	5	12	12
Стабільність формату	стабільно (2/2, JSON валідний)	стабільно (2/2, JSON валідний)	стабільно (2/2, JSON валідний)
Потрібні ресурси	~2–3 ГБ RAM, CPU	~4–6 ГБ RAM, CPU/GPU	немає локальних вимог, лише інтернет
Вартість	безкоштовно (крім електрики)	безкоштовно (крім електрики)	безкоштовний ліміт швидко вичерпується (429 Too Many Requests), далі платно
Куди йдуть дані	залишаються на комп'ютері	залишаються на комп'ютері	надсилаються на сервери Google
Працює без інтернету	так	так	ні
Коли обирати саме її	приватні/чутливі дані, прості задачі, офлайн-режим	коли потрібна трохи краща якість за ту саму ціну (0 грн) і є запас RAM	коли критична якість відповіді і швидкість генерації, приватність не критична

Загальні висновки

- Локальна й хмарна моделі використовують єдиний інтерфейс, тому перехід між ними не потребує змін у логіці програми — це основа стратегії резервування провайдерів у реальних проєктах;
- Затримка відповіді складається з двох незалежних показників — TTFT та швидкості генерації, висновки про те, «яка модель швидша», без їх розділення є некоректним;
- Режим міркування є інструментом із чіткою областю застосування: він окупається на багатокроковому виведенні й є чистою перевитратою на фактичних питаннях і переказі;
- Промпт та system-повідомлення є ненадійним засобом керування форматом відповіді: пряму інструкцію можуть проігнорувати моделі різного розміру, включно з хмарною. Надійність досягається програмною валідацією, а не формулюванням;
- Мовні моделі є недетермінованими системами, тому будь-яке вимірювання потребує повторів і усереднення.